



# Tecnológico de Monterrey

INSTITUTO TECNOLÓGICO Y DE ESTUDIOS  
SUPERIORES DE MONTERREY  
Campus Monterrey

**Reporte formal actividad:**  
**Diagnóstico por Computadora**

**Miembros del equipo**

Francisco Valadez Rojas	A01610820
Jesús Gabriel Leos Perales	A01412140
Andres Martín Vivanco Palacios	A01705733
Edio Mauricio Llerena Mancías	A00828309

**Profesores:**

José Tamez Peña  
Martha Rebeca Canales

Monterrey, Nuevo León  
12 de junio de 2022

## 1. ABSTRACT

La imagenología se ha vuelto un área muy importante para el diagnóstico de diferentes patologías en el cuerpo, pero esta solo puede ser implementada y analizada de la forma correcta por un experto o usando machine learning. Entrenando estos programas para que analicen las imágenes. En este paper se analizan distintos de estos métodos de aprendizaje como KNN, SVM, Naive Bayes, Adaboost y GBM para la extracción de las características de las imágenes. Se comenzó con el análisis de un melanoma para la clasificación de lesiones por computadora utilizando el software Matlab. En este software pudimos realizar el código de forma correcta, pero hubo algunos errores de caracterización, por lo que pasamos a los otros métodos en los que encontramos que los mejores resultados fueron dados por los métodos de Adaboost y GBM.

Keywords - *Imagenología, Machine learning, Matlab, Adaboost y GBM.*

## 2. INTRODUCCIÓN

La imagenología médica se puede definir como un conjunto de modalidades de adquisición de imágenes correspondientes a diferentes zonas del cuerpo humano, sirviendo como información visual para emitir un diagnóstico oportuno y específico. Las modalidades más comunes de imagenología médica son los rayos x, la tomografía computarizada, la resonancia magnética

nuclear, la imagenología nuclear y la imagenología por ultrasonido. [5]

El diagnóstico por métodos de radiografía tiene sus inicios a principios de los años 1800, que se empezó a conocer con el nombre de rayos x. El método más primitivo para la obtención de imágenes es usar un tubo de rayos X, una lámina sensible a los rayos emitidos o un receptor que es colocado en un chasis de la máquina, cuidadosamente diseñado para capturar la energía liberada por el haz de rayos x. Anteriormente, las imágenes obtenidas eran producidas por la exposición directa a los haces de rayos x, mientras que hoy en día, "la imagen de rayos X se produce cuando el haz de rayos X interaccionan con cristales especiales de fósforo contenidos en pantallas intensificantes localizadas dentro del chasis filmico. Cuando los rayos X interaccionan con los cristales de fósforo, se produce luz de una longitud de onda específica, que expone la película de rayos X". El método anterior vuelve más eficiente a la máquina, disminuyendo la cantidad de radiación necesaria para crear una imagen.

El receptor de imágenes ha evolucionado desde las placas de vidrio que se usaban inicialmente, como los materiales de poliéster, hasta las imágenes digitalizadas, incorporando más elementos a la arquitectura de una máquina de rayos x.

Los avances en los últimos años han sido notables, mejorando considerablemente el diagnóstico por imagen, habiéndose convertido en el principal método para confirmar o respaldar un diagnóstico dado por

un especialista de la salud. El procesamiento digital de imágenes son conjunto de técnicas que están basadas en la representación y digitalización de una imagen, facilitando sus análisis computacional para obtener información importante, tanto por un usuario o un sistema de visión artificial. [4]

Para aplicar la inteligencia artificial y sus variantes, como el deep learning, representation learning, etc., se definen 3 escenarios para su aplicación: screening o tamizaje, reemplazo y complementación.

Screening: se utiliza como herramienta para detectar y clasificar la probabilidad de una enfermedad, dando como resultado positivo o negativo.

Reemplazo: Esta variante reemplaza la presencia del personal médico. Se recomienda solamente cuando los resultados son más precisos y reproducibles, así como fáciles de obtener, para disminuir la probabilidad de error.

Complementación: con esta tecnología, el médico realiza su diagnóstico, y con un sistema de inteligencia artificial, puede ocurrir una concordancia en el diagnóstico, diagnóstico diferenciales, aportar información adicional o brindar otras herramientas para poder mejorar el tratamiento del paciente. [1]

Por otro lado, el cáncer de piel es el tipo más común de cáncer entre todos, y el melanoma solo conforma el 1% del total de casos, pero es el que más muertes causa al año.

Para el año 2022, en Estados Unidos, la cifra aproximada de casos de melanoma son de

99,780 casos, y morirán aproximadamente 7650 personas. En México, no se cuentan con datos epidemiológicos claros a cerca de la prevalencia y diagnóstico del melanoma maligno, pero se sabe que ocupamos el tercer lugar a nivel mundial (14.1%) después de enfermedades como el carcinoma basocelular y el espinocelular. [3]

Más específicamente, el melanoma es una neoplasia por una mutación en los melanocitos, generando células atípicas que dañan la piel en la mayoría de los casos. Este tipo de tumores presenta una alta resistencia a la quimioterapia y radioterapia, pueden o no presentar una pigmentación diferente a la normal, así como una gran capacidad metastásica. " El diagnóstico temprano es importante ya que la supervivencia disminuye de manera drástica cuando la neoplasia se profundiza en la dermis". [2]

Tomando en cuenta toda la información presentada, consideramos que la programación y definición de algoritmos matemáticos basados en machine learning pueden convertirse en una herramienta que evita muchas muertes, ofreciendo un diagnóstico oportuno de lesiones dérmicas relacionadas con tejido cancerígeno. El correcto aprovechamiento de esta tecnología disminuirá gastos a los gobiernos de muchos países alrededor del mundo.

### 3. OBJETIVO

El objetivo general de este trabajo es evaluar varios modelos matemáticos de Machine Learning y entrenar a cada uno de ellos en la identificación y clasificación de lesiones dérmicas correspondientes a melanomas y otras condiciones cutáneas, como el nevus o la queratosis seborreica con el fin de obtener un modelo predictivo que sea capaz de emitir un diagnóstico acertado en base a imágenes.

Uno de los objetivos específicos es utilizar distintos lenguajes de programación, como lo pueden ser MATLAB, R studio, etc., para hacer comparaciones de los mismos métodos implementados en dos o más interfaces de programación.

#### 4. MARCO TEÓRICO

##### Matriz de confusión

Una matriz de confusión es una tabla que se utiliza para gráficamente evaluar el rendimiento de un modelo de clasificación resultante del aprendizaje automático.

Como ejemplo, en la figura #, se puede observar la estructura de una matriz de confusión, donde podemos observar que en la primera diagonal se encuentran los verdaderos positivos y verdaderos negativos, mientras que en la segunda diagonal observamos los falsos positivos y falsos negativos.

		Actual Values	
		Yes	No
Predicted Values	Yes	True Positive	False Positive
	No	False Negative	True Negative

Para evaluar varios parámetros que caracterizan a una matriz de confusión, existen varias fórmulas para medir matemáticamente el rendimiento de esta misma.

Para medir la exactitud, es decir, la proporción de predicciones que midió correctamente el algoritmo de aprendizaje automático, se utiliza la siguiente fórmula:

$$Accuracy = \frac{\# \text{ of correct predictions}}{\text{total \# of predictions}} = \frac{TP + TN}{TP + TN + FP + FN}$$

Por otro lado, para medir la precisión, el valor que nos dice cual es la proporción de resultados predecidos realmente es verdadera, la fórmula es la siguiente:

$$Precision = \frac{TP}{TP + FP}$$

La sensibilidad es la proporción de la cantidad total de predicciones pertinentes que se recuperaron realmente, para lo cuál, se utiliza la siguiente fórmula:

$$Recall = \frac{TP}{TP + FN}$$

La especificidad, es el valor numérico que mide la proporción de verdaderos negativos

que se identificaron de manera correcta, básicamente lo opuesto a la sensibilidad, siendo su fórmula la siguiente:

$$Specificity = \frac{TN}{TN + FP}$$

Por último, la prueba F1 es una medida de precisión de una prueba, siendo técnicamente la media armónica de precisión y recuperación, cuya escala se mide desde el 0 al 1, para medir qué tan robusto y preciso es un modelo predictivo:

$$F1\ score = \frac{2 * (precision * recall)}{precision + recall} = \frac{2TP}{2TP + FP + FN}$$

## KNN

El método KNN (K-nearest Neighbor) es uno de los algoritmos de machine learning más simples que se basan en la técnica de aprendizaje supervisado. Este algoritmo asume una similitud entre los nuevos datos y los casos disponibles y los encasilla en una nueva categoría lo más similar a las categorías disponibles. Es importante destacar que este método es un algoritmo no paramétrico, significando que no asume on underlying data. También es llamado un algoritmo de aprendizaje perezoso, por que no aprende del set de entrenamiento, sino que guarda los datos y al momento de la clasificación, realiza una acción en el dataset



Figura 2.

## SVM

Este método fue desarrollado en la década de los 90's, que empezó como un método de clasificación binaria, se ha modificado su aplicación hasta la resolución de problemas de clasificación múltiple y regresión. Se le considera uno de los mejores clasificadores para situaciones de aprendizaje automático, siendo un referente dentro de este ámbito. Las máquinas de vector soporte están fundamentadas en el "Maximal Margin Classifier", que a su vez, está basado en el concepto del hiperplano.




Figura 1.

## Naive Bayes

Este es uno de los algoritmos más simples pero a la vez eficientes y poderosos para la clasificación, mismo que está basado en el teorema de Bayes, una suposición de independencia entre las variables predictoras. "El clasificador Naive Bayes asume que el efecto de una característica particular en una clase es independiente de otras características. Por ejemplo, un solicitante de préstamo es deseable o no dependiendo de sus ingresos, historial de préstamos y transacciones anteriores, edad y ubicación. Incluso si estas características son interdependientes, estas características se consideran de forma independiente. Esta suposición simplifica la computación, y por eso se considera ingenua."

$$P(h | D) = \frac{P(D | h)P(h)}{P(D)}$$

## Adaboost

Este es un método cuyo propósito es mejorar el desempeño de aprendizaje supervisado mediante una combinación lineal de clasificadores débiles para al final obtener un clasificador final con una muy buena robustez. "Una de las técnicas más populares de Boosting es el algoritmo Boosting Adaptativo (AdaBoost). Este algoritmo, mediante un entrenamiento iterativo de los clasificadores débiles o de base, le asigna mayor importancia a los datos mal clasificados anteriormente, y

de esta manera obtiene un nuevo clasificador. Logra, de esta forma, adaptarse y obtener mejores resultados aumentando la precisión del algoritmo.

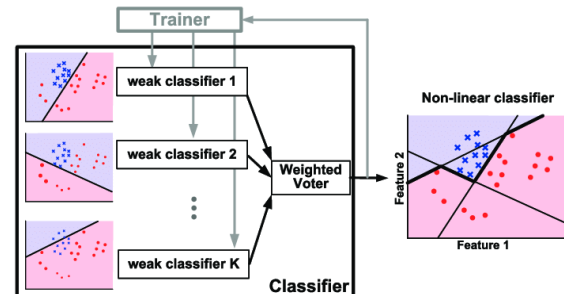


Figura 3.

## GBM

Este modelo está formado por un conjunto de árboles de decisión individuales, entrenados de forma secuencial, de modo que el siguiente árbol trata de corregir los errores de los anteriores. Cada nueva predicción se forma tomando en cuenta las predicciones anteriores de todos los árboles individuales que forman al modelo. " Los métodos estadísticos y de machine learning basados en árboles engloban a un conjunto de técnicas supervisadas no paramétricas que consiguen segmentar el espacio de los predictores en regiones simples, dentro de las cuales es más sencillo manejar las interacciones. Es esta característica la que les proporciona gran parte de su potencial".




Figura 4.

## 5. METODOLOGÍA

En el área de diagnóstico existen características que ayudan a un diagnóstico correcto para poder decidir tratamientos y tener un pronóstico acertado en cuanto a la salud del paciente. La radiómica extrae características de las imágenes médicas que no pueden verse a simple vista. Al utilizar algoritmos distintos como los mencionados en el marco teórico se pueden extraer las características mencionadas anteriormente.

En la evaluación de la clasificación de lesiones de piel por métodos de Aprendizaje por Computadora con sets de entrenamiento, se utilizó una base de datos anexada en el documento. Este anexo contiene Learning Melanoma, Matlab Scripts, Skin Lesions y Radiomics Workshop. Para lograr hacer la radiómica primero se calibraron las imágenes a utilizar, después se segmentan estas imágenes. Al tener las imágenes segmentadas se pueden extraer las características que no son visibles a simple vista. Posteriormente se pueden evaluar estas características de las imágenes y hacer el proceso de Machine Learning para poder aprender de las imágenes analizadas previamente y mejorar la extracción de características. Mejorando este proceso se puede tener un mejor diagnóstico y características más sencillas de visualizar.

## 6. RESULTADOS

A continuación se mostrarán los resultados obtenidos de los diferentes procesamiento de imágenes con la base de datos utilizada en MatLab para diferentes melanomas. El código funciona correctamente en la mayoría de los casos. Sin embargo, se pueden notar algunos errores al momento de realizar el "shaving" como se mostrará a continuación.

### Melanoma

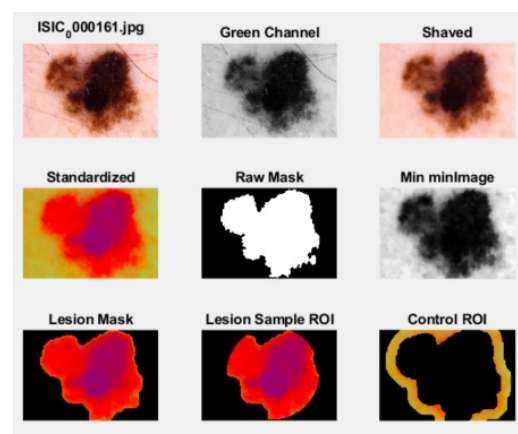


Figura 5. Ejemplo de una segmentación correcta de melanoma.

Media	Standard deviation	Skewness	Kurtosis	Volumen	Superficie	GLCM
9.85E-02	8.39E-02	1.15E-01	-7.66E-02	2.86E+04	1.06E+05	1.71

Figura 6. Características extraídas de la segmentación correcta de melanoma.




Figura 7. Ejemplo de una segmentación errónea de melanoma.

Media	Standard deviation	Skewness	Kurtosis	Volumen	Superficie	GLCM
6.95E-02	1.06E-01	1.30E-01	-4.55E-02	2.39E+04	6.63E+04	1.75

Figura 8. Características extraídas de la segmentación errónea de melanoma.

Nevus




Figura 9. Ejemplo de una segmentación correcta de Nevus.

Media	Standard deviation	Skewness	Kurtosis	Volumen	Superficie	GLCM
7.39E-01	3.72E-02	5.28E-02	-2.44E-02	3.45E+04	8.25E+04	1.73

Figura 10. Características extraídas de la segmentación correcta de Nevus.




Figura 11. Ejemplo de una segmentación errónea de Nevus.

Media	Standard	Skewness	Kurtosis	Volumen	Superficie	GLC
-------	----------	----------	----------	---------	------------	-----

deviation				s		ie		M	
4.59E-01	1.05E-01	1.18E-01	5.60E-02	2.15E+04	6.89E+04	1.81			

Figura 12. Características extraídas de la segmentación errónea de Nevus.

Seborrheic keratosis




Figura 13. Ejemplo de una segmentación correcta de Seborrheic keratosis.

Media	Standard deviation	Skewness	Kurtosis	Volumen	Superficie	GLCM
3.97E-01	2.83E-02	4.32E-02	-3.01E-02	3.29E+04	7.95E+04	1.79

Figura 14. Características extraídas de la segmentación correcta de Seborrheic keratosis.




Figura 15. Ejemplo de una segmentación errónea de Seborrheic keratosis.

Media	Standard deviation	Skewness	Kurtosis	Volumen	Superficie	GLCM
2.58E-01	4.97E-02	6.33E-02	-1.96E-02	1.40E+04	9.06E+04	1.72

Figura 16. Características extraídas de la segmentación errónea de Seborrheic keratosis.



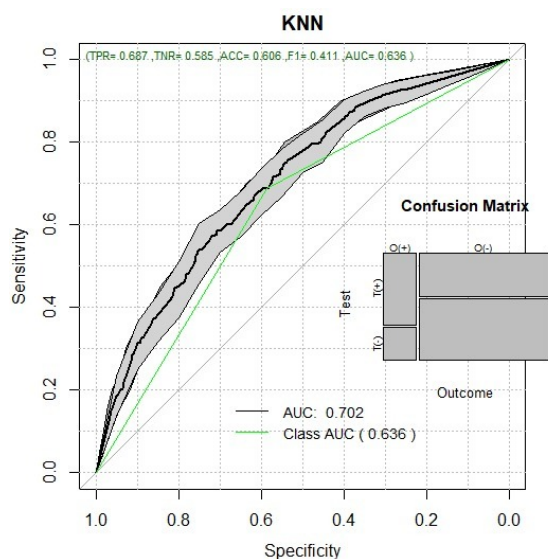


Figura 17. Análisis con KNN




Figura 20. Características extraídas de la imagen anterior:




Figura 18. Características extraídas de la imagen anterior:

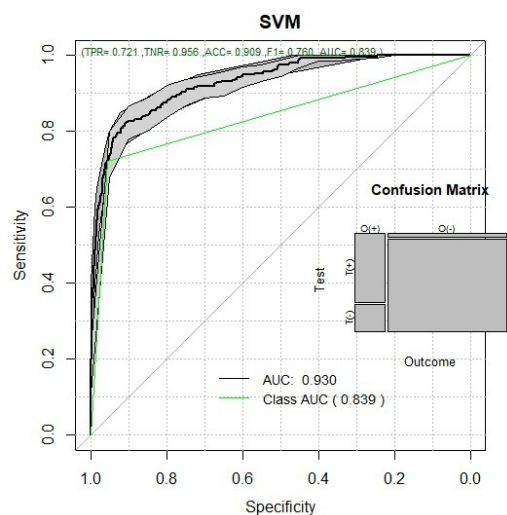


Figura 19. Análisis con SVM

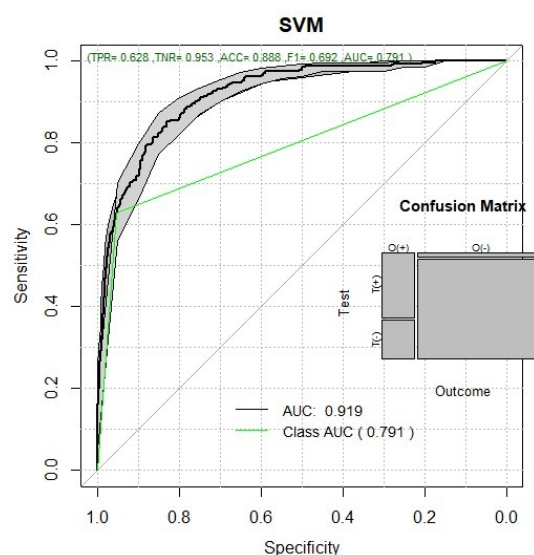


Figura 21. Características extraídas de la imagen anterior:




Figura 22. Características extraídas de la imagen anterior:

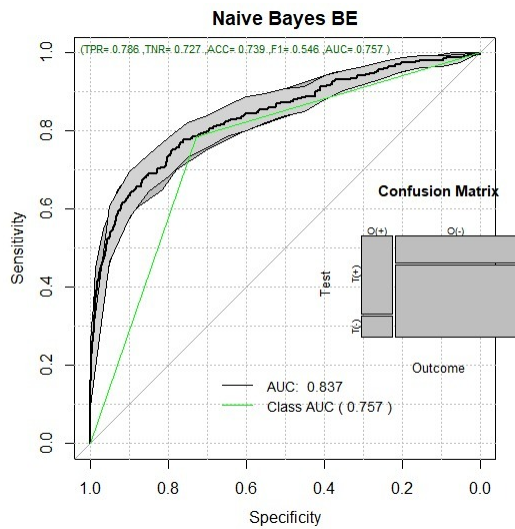


Figura 23. Características extraídas de la imagen anterior:

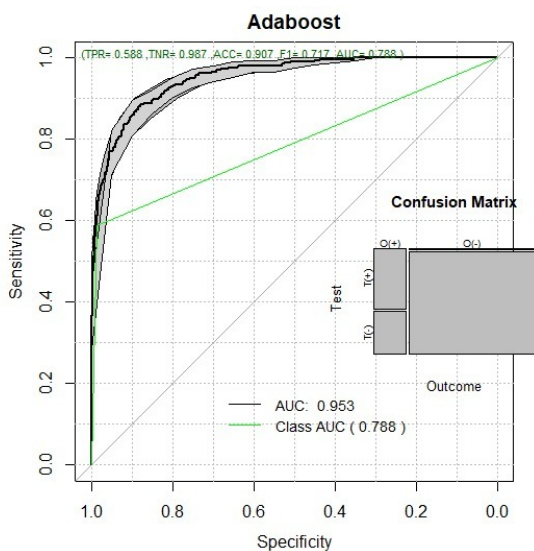


Figura 24. Características extraídas de la imagen anterior:

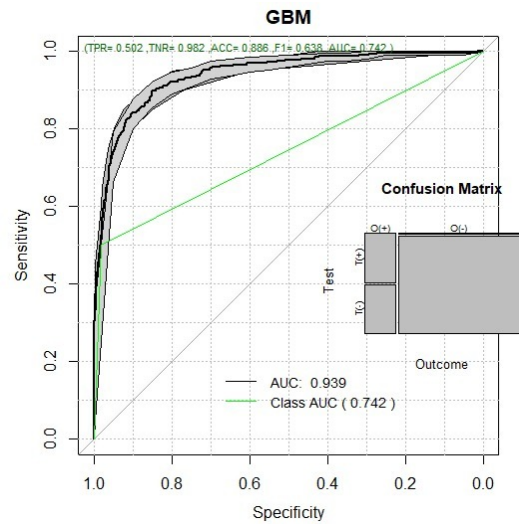


Figura 25. Características extraídas de la imagen anterior:

## 7. DISCUSIÓN

Después de obtener los resultados de cada uno de los métodos, procedimos a compararlos entre sí para determinar cuál era el mejor. El área bajo la curva del método Adaboost es de 0.953 lo que es un indicativo de que los valores TPR y TNR son altos. Por otro lado los métodos KNN y Naive Bayes son los menos eficientes, ya que ambos arrojan un valor de 0.702 en el área bajo la curva.

Analizando las imágenes del melanoma, podemos decir que rara vez existen ciertos casos donde el “shaving” no se hace correctamente y fusiona el contorno del ROI. En nuestro caso en la realización de esta investigación, en la mayoría de las imágenes el opening y el closing funcionan correctamente para realizar el “shaving”.

## 8. CONCLUSIÓN

Uno de los métodos de diagnóstico más comunes para afecciones dermatológicas es una biopsia cutánea, sin embargo cuando se trata de un melanoma, este únicamente sirve como un método de pronóstico más que de diagnóstico. Es por esto que nuestra intención con este diagnóstico de computadora es poder brindarle a los médicos expertos, un método de diagnóstico más preciso. [11]

Utilizamos los métodos de machine learning y algoritmos de deep learning para poder obtener un diagnóstico de melanoma con una computadora.

Posteriormente a realizar este estudio, llegamos a la conclusión de que los diagnósticos por computadora pueden reemplazar o complementar las biopsias cutáneas debido al análisis de imágenes médicas que se obtienen con los métodos de machine learning. Esta conclusión nos dio la idea de que este procedimiento podría ser utilizado para la detección de diferentes tipos de afecciones cutáneas de una manera no invasiva y arrojando una mejor calidad de resultados que una biopsia que le permita a los médicos hacer mejores diagnósticos.

## 9. REFERENCIAS

[1] Ramos, D. U. E. (2020, 30 diciembre). *INTELIGENCIA ARTIFICIAL EN EL AREA MEDICA; APLICADA EN LA IMAGENOLOGÍA* | Revista Digital de Tecnologías Informáticas y Sistemas. Redtis. Recuperado 13 de junio de 2022, de <https://www.redtis.org/index.php/Redtis/article/view/73>

[2] Barrera, A. (2019). *Características clínicas e histopatológicas del melanoma nodular y acral lentiginoso en pacientes mexicanos*. Medigraphic. Recuperado 13 de junio de 2022, de <https://www.medigraphic.com/pdfs/cosmetica/dcm-2019/dcm193c.pdf>

[3] American Cancer Society. (s. f.). *Estadísticas importantes sobre el cáncer de piel tipo melanoma*. Cancer.org. Recuperado 13 de junio de 2022, de [https://www.cancer.org/es/cancer/cancer-de-piel-tipo-melanoma/acerca/estadisticas-clave.html#:~:text=Se%20diagnosticar%C3%A1n%20aproximadamente%2099%2C780%20nuevos,mujeres\)%20a%20causa%20de%20melanoma](https://www.cancer.org/es/cancer/cancer-de-piel-tipo-melanoma/acerca/estadisticas-clave.html#:~:text=Se%20diagnosticar%C3%A1n%20aproximadamente%2099%2C780%20nuevos,mujeres)%20a%20causa%20de%20melanoma).

[4] McGraw Hill Medical. (s. f.). *Introducción a la obtención de imágenes (imagenología) para profesionales de la salud | Imagenología para el profesional en ciencias de la salud | AccessMedicina | McGraw Hill Medical*. Access Medicina. Recuperado 13 de junio de 2022, de <https://accessmedicina.mhmedical.com/content.aspx?bookid=2404&ionid=187820652>


[5] Bellera, J. (s. f.). *Bases del Procesamiento de Imágenes Médicas*. ULA. Recuperado 13 de junio de 2022, de [http://www.saber.ula.ve/redtelemedicina/TallerTelemedicina/j\\_bellera-01.pdf](http://www.saber.ula.ve/redtelemedicina/TallerTelemedicina/j_bellera-01.pdf)

[6] *K-Nearest Neighbor(KNN) Algorithm for Machine Learning - Javatpoint.* (s. f.). Www.Javatpoint.Com. Recuperado 13 de junio de 2022, de <https://www.javatpoint.com/k-nearest-neighbor-algorithm-for-machine-learning>

[7] Rodrigo, J. A. (2017). *Máquinas de Vector Soporte (Support Vector Machines, SVMs)*. Cienciadedatos.net. Recuperado 13 de junio de 2022, de [https://www.cienciadedatos.net/documentos/34\\_maquinas\\_de\\_vector\\_soporte\\_support\\_vector\\_machines](https://www.cienciadedatos.net/documentos/34_maquinas_de_vector_soporte_support_vector_machines)

[8] Grupo IANUS. (2019, 22 marzo). *RepHipUNR*. UNR. Recuperado 13 de junio de 2022, de <https://rephip.unr.edu.ar/handle/2133/14282#:~:text=Una%20de%20las%20t%C3%A9cnicas%20m%C3%A1s,manera%20obtiene%20un%20nuevo%20clasificador.>

[9] Amat, J. A. (2020). *Gradient Boosting con python*. Cienciadedatos.net. Recuperado 13 de junio de 2022, de [https://www.cienciadedatos.net/documentos/py\\_09\\_gradient\\_boosting\\_python.html](https://www.cienciadedatos.net/documentos/py_09_gradient_boosting_python.html)

[10] Gonzalez, L. (2020, 21 agosto). *Naive Bayes – Teoría*.  Aprende IA. Recuperado 13 de junio de 2022, de <https://aprendeia.com/naive-bayes-teoria-machine-learning/>

[11] Llamas-Velasco, M., & Paredes, B. E. (2012, January 1). *La biopsia Cutánea: Bases*

*fundamentales. parte I.* Actas Dermo-Sifiliográficas. Retrieved June 13, 2022, from <https://www.actasdermo.org/es-la-biopsia-cutanea-bases-fundamentales--articulo-S000173101100278X>

## 10. ANEXOS